

Faker Personendaten analysieren

Datengenerierung

Für die Datengenerierung wurde die Python-Bibliothek Faker verwendet.

500000 Personen mit vor und nachname wurden erzeugt und in einer SQLite-Datenbank gespeichert.

```
sqlite> .mode table
sqlite> .headers on
sqlite> .timer on
```

```
SELECT COUNT(*) FROM personen;
```

```
+-----+
| COUNT(*) |
+-----+
| 500000   |
+-----+
```

```
Run Time: real 0.007 user 0.006832 sys 0.000000
```

Streuung - gleichmäßige Verteilung der erzeugte Vornamen

Hier kann man nicht einfach eine mathematische Varianz nehmen, da zwischen Namen, keine numerische Distanz besteht. Es wird untersucht, wie oft die einzelnen Vornamen vorkommen.

```
SELECT vorname, COUNT(*) as Count
FROM personen
GROUP BY vorname
ORDER BY Count DESC;
```

```
Run Time: real 0.282 user 0.278026 sys 0.004000
```

Index

Zuerst wurde die suche ohne index durchgeführt.

```
SELECT COUNT(*)
FROM personen
WHERE vorname='Anna';
```

```
+-----+
| COUNT(*) |
+-----+
| 256      |
+-----+
```

```
Run Time: real 0.048 user 0.044805 sys 0.000000
```

256 Personen mit dem Vornamen 'Anna' gefunden in 0,048 sec.

```
PRAGMA page_count;
```

```
+-----+
| page_count |
+-----+
| 2869      |
+-----+
```

```
Run Time: real 0.000 user 0.000165 sys 0.000000
```

```
PRAGMA page_size;
```

```
+-----+
| page_size |
+-----+
| 4096      |
+-----+
```

```
Run Time: real 0.000 user 0.000069 sys 0.000000
```

DB hatte vor dem Index 2869 Seiten x 4096 Bytes ist ungefähr 11,2 MB

Dannach wurde ein Index auf der Spalte 'vorname' erstellt:

CREATE INDEX Syntax:

```
CREATE INDEX index_name
ON table_name (column1, column2, ...);
```

Auf meine Tabelle angepasst:

```
CREATE INDEX idx_vorname
ON personen(vorname);
```

Nach dem erstellen des Index:

```
SELECT COUNT(*)
FROM personen
WHERE vorname='Anna';
```

```
+-----+
| COUNT(*) |
+-----+
| 256      |
+-----+
```

```
Run Time: real 0.000 user 0.000199 sys 0.000013
```

Wieder 256 Personen mit dem Vornamen 'Anna' in 0,000 sec

```
PRAGMA page_count;
```

```
+-----+
| page_count |
+-----+
| 4778      |
+-----+
```

```
+-----+
Run Time: real 0.000 user 0.000112 sys 0.000008
```

Die DB-Große nach dem Index ist 4778 Seiten x 4096 Bytes ist ungefähr 18,7 MB.

Shorter to db size

```
select page_count * page_size from pragma_page_count(), pragma_page_size();
```

Der Index verändert nicht die Daten sondern beschleunigt die Suche

Der Index benötigte für 500000 Datensätze ungefähr 7,5 MB zusätzlichen Speicherplatz

Bias

Für die weitere Untersuchung wurde eine neue DB mit 500000 Personen erstellt.

Dabei wurden absichtlich 250000 Personen mit dem Namen 'Anna' erzeugt, und noch weitere 250000 mit 'random fake names'

```
SELECT COUNT(*) FROM personen WHERE vorname='Anna';
```

```
+-----+
| COUNT(*) |
+-----+
| 250119   |
+-----+
```

```
Run Time: real 0.047 user 0.043366 sys 0.003445
```

In den anderen 250000 random erzeugten Namen gab es noch 119 mit dem Vornamen 'Anna'.

Ohne Index dauerte die Suche nach 'Anna' 0,047 sec, nach dem erstellen des Index dauerte 0,017 sec.

Der Index beschleunigte die Suche auch dann, wenn der gesuchte Name mehr als die Hälfte der Datensätze ausmacht.